

Μη σχεσιακές βάσεις δεδομένων

Από τους πίνακες στα έγγραφα

Εβδομάδα 1

Μέρος 2ο



Αθανάσιος Χριστόπουλος, Ph.D.

Αν. Καθηγητής, Τμήμα Φυσικών Επιστημών. Κέντρο Μαθησιακής Αναλυτικής, Πανεπιστήμιο του Τούρκου, Φινλανδία
atchri@utu.fi

Τέσσερα μοντέλα, ο ίδιος φοιτητής

Κλειδί-τιμή

student:1042 → ένα «πακέτο» με όλα τα στοιχεία του. Η βάση **δεν ξέρει τι περιέχει**.

«Φέρε μου την τιμή αυτού του κλειδιού.»

Έγγραφο

Ένα έγγραφο με όνομα, έτος και λίστα μαθημάτων με βαθμούς. Η βάση **«βλέπει» κάθε πεδίο**.

«Φέρε μου ολόκληρο το αντικείμενο.»

Ευρείες στήλες

Μια γραμμή με κλειδί το 1042, με όλη τη δραστηριότητα του φοιτητή **ταξινομημένη κατά χρόνο**.

«Γράψε γρήγορα, διάβασε ανά κλειδί και χρόνο.»

Γράφοι

Ο κόμβος «φοιτητής 1042», με **ακμές** προς τα μαθήματά του και προς όσους απαντά στο φόρουμ.

«Πώς συνδέονται αυτά μεταξύ τους;»

Τα ίδια δεδομένα, με τέσσερις τρόπους. Κάθε μοντέλο διευκολύνει ένα είδος ερωτήματος.

Το ερώτημα επιλέγει το μοντέλο, όχι το αντίστροφο.

Κλειδί–τιμή

Κάθε εγγραφή είναι ένα **ζεύγος κλειδιού–τιμής** (key–value): ένα μοναδικό κλειδί και μια τιμή. Η βάση βρίσκει την τιμή από το κλειδί, χωρίς να εξετάζει τι περιέχει.

Το απλούστερο μοντέλο NoSQL

Λειτουργίες

- **Αποθήκευση:** SET κλειδί τιμή.
- **Ανάκτηση:** GET κλειδί.
- **Διαγραφή:** DEL κλειδί.

Γιατί είναι γρήγορο;

- Συχνά όλα τα δεδομένα βρίσκονται στη **μνήμη RAM**.
- Το κλειδί ορίζει και **σε ποιον διακομιστή** βρίσκεται η τιμή.

Παράδειγμα: συνεδρίες και μετρητές (Redis)

```
> SET session:9f3a "user=1042"
OK
> EXPIRE session:9f3a 1800
(integer) 1
> GET session:9f3a
"user=1042"
> INCR views:video:17
(integer) 101
```

- Το κλειδί **περιγράφει τι αποθηκεύεται**: `session:9f3a`, `views:video:17`.
- **EXPIRE**: η συνεδρία **διαγράφεται μόνη της** μετά από 1.800 δευτερόλεπτα (30 λεπτά).
- **INCR**: ο μετρητής αυξάνεται **μέσα στη βάση**, με ασφάλεια ακόμη κι όταν πολλοί τον αυξάνουν ταυτόχρονα.

Η τιμή μπορεί να έχει δομή

```
> ZADD quiz:7 18 1042 15 1077 19 1093
(integer) 3
> ZRANGE quiz:7 0 2 REV WITHSCORES
1) "1093"
2) "19"
3) "1042"
4) "18"
5) "1077"
6) "15"
```

- **Ταξινομημένο σύνολο (sorted set):** πίνακας κατάταξης που ενημερώνεται αμέσως.
- Υπάρχουν και λίστες, σύνολα, πίνακες κατακερματισμού (hashes), ροές (streams).
- Η πρόσβαση γίνεται **πάντα μέσω κλειδιού**: εδώ, `quiz:7`.

Πού χρησιμοποιείται το κλειδί-τιμή;

Κρυφή μνήμη (cache)

Αποτελέσματα ερωτημάτων και σελίδες που **ζητούνται συχνά**, ώστε να μη φορτώνεται η κύρια βάση.

Όρια αιτημάτων

Πόσα αιτήματα έκανε ένας χρήστης το τελευταίο λεπτό, με μετρητή που **λήγειμόνος του**.

Ουρές εργασιών

Εργασίες που **περιμένουν σειρά**, π.χ. η αποστολή ειδοποιήσεων.

Συστήματα: Redis, Amazon DynamoDB, Memcached.

Το όριο του κλειδιού–τιμής

● Εύκολο

- «Φέρε τη συνεδρία `session:9f3a`.»
- «Αύξησε τον μετρητή του βίντεο 17.»

● Δύσκολο

- «Όλοι οι φοιτητές με βαθμό πάνω από 8.»
- «Οι συνεδρίες όσων παρακολουθούν ένα συγκεκριμένο μάθημα.»

Η βάση γνωρίζει **μόνο κλειδιά**.

Κάθε ερώτημα με βάση το περιεχόμενο χρειάζεται άλλη δομή ή άλλο σύστημα.

Έγγραφα

Κάθε εγγραφή είναι ένα **έγγραφο (document)**: σύνολο πεδίων και τιμών σε μορφή τύπου JSON. Μια τιμή μπορεί να είναι **λίστα ή άλλο έγγραφο**.

Το μοντέλο της MongoDB

Σε αντίθεση με το κλειδί-τιμή

Η βάση «βλέπει» μέσα στο έγγραφο: ερωτήματα και ευρετήρια σε **οποιοδήποτε πεδίο**.

Ευέλικτη δομή

Τα έγγραφα ομαδοποιούνται σε **συλλογές**, όπως οι γραμμές σε πίνακες.

Δύο έγγραφα της ίδιας συλλογής μπορεί να έχουν διαφορετικά πεδία.

JSON σε ένα λεπτό

```
{  
  "course_id": "DB101",  
  "title": "Βάσεις Δεδομένων",  
  "semester": 3,  
  "online": true,  
  "tags": ["SQL", "NoSQL"]  
}
```

- `{ }`: έγγραφο (αντικείμενο), με **ζεύγη πεδίου-τιμής** χωρισμένα με κόμμα.
- Τα ονόματα των πεδίων γράφονται **σε διπλά εισαγωγικά**.
- **Τιμές**: κείμενο, αριθμοί, `true` και `false`, `null`, λίστες σε `[ ]`, άλλα έγγραφα.

Παράδειγμα εγγράφου: ο φοιτητής ολόκληρος

```
{
  "_id": 1042,
  "name": "Μαρία Παπαδοπούλου",
  "year": 2024,
  "enrolments": [
    { "course_id": "DB101", "grade": 8.5 },
    { "course_id": "LA201", "grade": 9 }
  ]
}
```

- Ο φοιτητής και οι εγγραφές του στα μαθήματα, **σε ένα έγγραφο**.
- Οι εγγραφές είναι **λίστα εμφωλευμένων εγγράφων**.
- Ερώτημα σε εμφωλευμένο πεδίο, **με τελεία**:
"enrolments.course_id".

Πίνακας ή συλλογή εγγράφων

● Πίνακας

- Όλες οι γραμμές έχουν **τις ίδιες στήλες**.
- Οι σχέσεις με άλλους πίνακες, με **ξένα κλειδιά**.
- **Τιμή που λείπει:** NULL στη στήλη.

● Συλλογή εγγράφων

- Κάθε έγγραφο έχει **τα δικά του πεδία**.
- Τα σχετικά δεδομένα **μέσα στο ίδιο έγγραφο**.
- **Τιμή που λείπει:** το πεδίο απλώς δεν υπάρχει.

Η συλλογή αντιστοιχεί στον πίνακα και το έγγραφο στη γραμμή.
Το έγγραφο όμως κουβαλά μαζί του και τα σχετικά του δεδομένα.

Ένα έγγραφο αντί για JOIN

1

ανάγνωση για ολόκληρο τον φοιτητή, αντί για σύνδεση πινάκων

Ό,τι διαβάζεται μαζί, αποθηκεύεται μαζί.

- Ταιριάζει όταν τα εμφωλευμένα δεδομένα **ανήκουν στο έγγραφο** και **δεν αυξάνονται χωρίς όριο**.

Πού χρησιμοποιούνται τα έγγραφα;

Κατάλογοι

Προϊόντα ή μαθήματα με χαρακτηριστικά που διαφέρουν **από είδος σε είδος**.

Προφίλ χρηστών

Προαιρετικά πεδία, ρυθμίσεις, προτιμήσεις.

Διαχείριση περιεχομένου

Άρθρα, σελίδες, υλικό μαθημάτων σε **ποικίλες μορφές**.

Εφαρμογές κινητών

Η εφαρμογή ανταλλάσσει JSON και η βάση κρατά τα έγγραφα **με την ίδια δομή**.

Συστήματα: MongoDB, Couchbase, Google Firestore, Apache CouchDB.

Το όριο των εγγράφων

N:M

σχέσεις πολλά-προς-πολλά:
φοιτητές και μαθήματα

Όταν πολλά έγγραφα περιέχουν τα ίδια δεδομένα, η αποθήκευσή τους μέσα σε κάθε έγγραφο σημαίνει **επανάληψη**.

- Αλλαγή του τίτλου ενός μαθήματος σημαίνει **ενημέρωση σε κάθε έγγραφο** φοιτητή που τον περιέχει.
- Ερωτήματα που διασχίζουν πολλές σχέσεις ταιριάζουν καλύτερα σε **σχεσιακή βάση** ή σε **γράφο**.

Ευρείες στήλες

Κάθε γραμμή έχει ένα κλειδί. Οι στήλες της ομαδοποιούνται σε **οικογένειες στηλών**, δηλαδή σε στήλες που **διαβάζονται μαζί**, π.χ. τα στοιχεία του φοιτητή χωριστά από τη δραστηριότητά του.

Μοντέλο wide-column: από το Bigtable στην Apache Cassandra

Αραιή, ταξινομημένη αποθήκευση

Κλειδί γραμμής, στήλη και χρονική σφραγίδα οδηγούν σε μία τιμή.

Οι στήλες που λείπουν δεν καταλαμβάνουν χώρο.

Γιατί «ευρείες»;

Μια γραμμή μπορεί να έχει **χιλιάδες στήλες**, και κάθε γραμμή **τις δικές της**.

Ευρείες στήλες ή αποθήκευση ανά στήλη;

● Ευρείες στήλες (Cassandra, HBase)

- Αποθήκευση **ανά γραμμή**, με ευέλικτες στήλες.
- Πολύ **γρήγορες εγγραφές**, ανάγνωση με το κλειδί της γραμμής.

● Αποθήκευση ανά στήλη (ClickHouse, Snowflake, Parquet)

- Οι τιμές **κάθε στήλης** αποθηκεύονται μαζί.
- **Γρήγορες συναθροίσεις** σε εκατομμύρια γραμμές, συνήθως με SQL.

Η ομοιότητα των ονομάτων παραπλανά. Οι πρώτες είναι **βάσεις NoSQL** για τα δεδομένα των εφαρμογών σε μεγάλη κλίμακα, οι δεύτερες κυρίως **εργαλεία ανάλυσης**.

Παράδειγμα: η δραστηριότητα ανά φοιτητή και χρόνο

```
CREATE TABLE activity_by_student (  
  student_id int,  
  ts timestamp,  
  type text,  
  details map<text, text>,  
  PRIMARY KEY ((student_id), ts)  
) WITH CLUSTERING ORDER BY (ts DESC);  
  
SELECT * FROM activity_by_student  
WHERE student_id = 1042 LIMIT 20;
```

- `student_id`: **κλειδί κατάτμησης**. Όλη η δραστηριότητα ενός φοιτητή βρίσκεται στον ίδιο κόμβο.
- `ts`: **κλειδί ταξινόμησης** (clustering). Τα πιο πρόσφατα πρώτα.
- Το ερώτημα διαβάζει μια **συνεχόμενη περιοχή του δίσκου**: γρήγορο, όσο κι αν μεγαλώσει η βάση.

Σχεδίαση με βάση το ερώτημα

Στις βάσεις ευρειών στηλών σχεδιάζουμε έναν πίνακα **για κάθε ερώτημα, όχι για κάθε οντότητα.**

Σχεδίαση με γνώμονα το ερώτημα (query-first design)

Παράδειγμα

Για «δραστηριότητα ανά μάθημα» χρειάζεται **δεύτερος πίνακας**, `activity_by_course`, με τα ίδια δεδομένα και άλλο κλειδί.

Το αντίθετο της κανονικοποίησης

Τα δεδομένα γράφονται **δύο φορές.**

Οι εγγραφές είναι φθηνές, ενώ οι αναγνώσεις πρέπει να είναι γρήγορες.

Πού χρησιμοποιούνται οι ευρείες στήλες;

Χρονοσειρές και αισθητήρες

Μετρήσεις που φτάνουν συνεχώς, **ανά συσκευή και χρόνο**.

Ροή κλικ σε μεγάλη κλίμακα

Εκατομμύρια συμβάντα την ημέρα, **ανά χρήστη και χρόνο**.

Ιστορικό μηνυμάτων

Συνομιλίες που διαβάζονται **ανά συνομιλία**, με τα πιο πρόσφατα πρώτα.

Συστήματα: Apache Cassandra, Apache HBase, ScyllaDB, Google Cloud Bigtable.

Γράφοι

Τα δεδομένα είναι **κόμβοι (οντότητες)** και **ακμές (σχέσεις)**. Και οι δύο μπορούν να έχουν ιδιότητες.

Μοντέλο γράφου ιδιοτήτων (property graph)

Οι σχέσεις αποθηκεύονται


Κάθε ακμή είναι **αποθηκευμένη σύνδεση**. Η μετάβαση από κόμβο σε κόμβο **δεν απαιτεί JOIN**.

Ερωτήματα διαδρομών

«Ποιοι συνδέονται με ποιους, σε δύο ή τρία βήματα;»

Εκεί οι γράφοι υπερέχουν.

Παράδειγμα: ποιος απαντά σε ποιον στο φόρουμ;



- **Κόμβοι:** φοιτητές. **Ακμές:** «απάντησε σε», με το πλήθος των απαντήσεων.
- Η Μαρία συγκεντρώνει τις περισσότερες απαντήσεις: **κεντρικός κόμβος**.
- Ο Κώστας δεν συνδέεται με κανέναν. Τέτοια δίκτυα μελετά η Μαθησιακή Αναλυτική, με την **ανάλυση κοινωνικών δικτύων**.

Δώδεκα απαντήσεις σε ένα νήμα του φόρουμ, ως γράφος. Επινοημένο παράδειγμα.

Ερώτημα σε γράφο: διαδρομή δύο βημάτων

```
MATCH (a:Student) -[:REPLIED_TO]->
      (b:Student) -[:REPLIED_TO]->
      (c:Student)
WHERE a <> c
RETURN a.name, b.name, c.name
```

- Ποιοι συνδέονται **μέσω ενός ενδιάμεσου**, σε δύο βήματα.
- **Σε SQL:** ο πίνακας των απαντήσεων συνδέεται **με τον εαυτό του**, ένα αντίγραφο του πίνακα για κάθε βήμα.
- Το ερώτημα διαβάζεται **όπως η διαδρομή** που περιγράφει.

Πού χρησιμοποιούνται οι γράφοι;

Κοινωνικά δίκτυα

Φίλοι, ακόλουθοι, **αλληλεπιδράσεις σε φόρουμ**.

Εντοπισμός απάτης

Λογαριασμοί που **μοιράζονται** συσκευές, διευθύνσεις ή τρόπους πληρωμής.

Γράφοι γνώσης

Έννοιες και οι σχέσεις τους, π.χ. τα **προαπαιτούμενα των μαθημάτων**.

Δίκτυα και διαδρομές

Συγκοινωνίες, δίκτυα υπολογιστών, αλυσίδες εφοδιασμού.

Συστήματα: Neo4j, Amazon Neptune.

Σύγκριση των τεσσάρων μοντέλων

	Κλειδί-τιμή	Έγγραφα	Ευρείες στήλες	Γράφοι
Μονάδα	ζεύγος κλειδιού-τιμής	έγγραφο τύπου JSON	γραμμή με οικογένειες στηλών	κόμβοι και ακμές
Αναζήτηση με	το κλειδί	οποιοδήποτε πεδίο	το κλειδί της γραμμής	διαδρομές
Δυνατό σημείο	ταχύτητα	ευελιξία	ρυθμός εγγραφών	σχέσεις
Όριο	τίποτε πέρα από το κλειδί	σχέσεις ανάμεσα σε έγγραφα	ερωτήματα που δεν προβλέφθηκαν	κατανομή σε πολλούς διακομιστές
Συστήματα	Redis, DynamoDB	MongoDB, Couchbase	Cassandra, HBase	Neo4j, Neptune

Και άλλα μοντέλα

Χρονοσειρών (time series)

Μετρήσεις με **χρονική σφραγίδα**, με συμπίεση και συναθροίσεις ανά διάστημα. Π.χ. InfluxDB, TimescaleDB.

Διανυσματικές (vector)

Αναζήτηση με βάση την **ομοιότητα διανυσματικών αναπαραστάσεων** (embeddings): η αναζήτηση πίσω από πολλές εφαρμογές παραγωγικής ΤΝ. Π.χ. Milvus, pgvector.

Πολλαπλών μοντέλων

Ένα σύστημα, περισσότερα μοντέλα: έγγραφα, γράφοι, κλειδί-τιμή. Π.χ. Azure Cosmos DB, ArangoDB.

Ο σύνδεσμος με τη Μαθησιακή Αναλυτική: η δήλωση xAPI

actor: ποιος;

`mailto:maria@example.org`

verb: τι έκανε;

`http://adlnet.gov/exapi/verbs/completed`, «ολοκλήρωσε»

object: σε τι;

`https://example.org/quiz/7`

result: με ποιο αποτέλεσμα;

βαθμός 0,85 στην κλίμακα 0 έως 1

timestamp: πότε;

ημερομηνία και ώρα, σε μορφή ISO 8601

Η βασική δομή είναι **ίδια σε κάθε πλατφόρμα**: έτσι δηλώσεις από διαφορετικά συστήματα μάθησης συγκεντρώνονται στην ίδια αποθήκη.

Αποθήκη μαθησιακών καταγραφών

Learning Record Store (LRS): δέχεται, αποθηκεύει και επιστρέφει δηλώσεις xAPI μέσω τυποποιημένης διεπαφής.

Experience API (xAPI)

Ένα παράδειγμα

Το Learning Locker, αποθήκη ανοιχτού κώδικα, κρατά τις δηλώσεις σε **MongoDB** και χρησιμοποιεί επίσης **Redis**.

Γιατί βάση εγγράφων;

Οι δηλώσεις είναι **έγγραφα JSON** με πεδία που **διαφέρουν ανά δραστηριότητα**.

Ποιο μοντέλο ταιριάζει;

Η πλατφόρμα θέλει να προτείνει μαθήματα: «Όσοι πήραν αυτό το μάθημα, πήραν και...». Ποιο μοντέλο δεδομένων ταιριάζει καλύτερα;

A Κλειδί-τιμή

B Έγγραφα

Γ Ευρείες στήλες

Δ Γράφος

01:30

Ποιο μοντέλο για ποια δεδομένα;

Συνεδρίες χρηστών

Ανάγνωση και εγγραφή με **ένα γνωστό κλειδί**, πολύ συχνά.

κλειδί-τιμή

Υλικό μαθημάτων

Κάθε είδος υλικού έχει **άλλα πεδία** και διαβάζεται ολόκληρο.

έγγραφα

Ροή κλικ χιλιάδων φοιτητών

Συνεχείς εγγραφές, ανάγνωση **ανά φοιτητή και χρόνο**.

ευρείες στήλες

Φόρουμ και προτάσεις μαθημάτων

Ερωτήματα για το **ποιος συνδέεται με ποιον**, σε ένα ή δύο βήματα.

γράφος

Βαθμοί και εγγραφές

Σταθερή δομή, **αυστηροί κανόνες**, αναφορές.

σχεσιακή

Η πλατφόρμα ως σύνολο

Κάθε είδος δεδομένων στο **σύστημα που του ταιριάζει**.

συνδυασμός

Βασικά συμπεράσματα

- 1 Κλειδί–τιμή, έγγραφα, ευρείες στήλες, γράφοι: κάθε μοντέλο **απαντά καλύτερα σε ένα είδος ερωτήματος.**
- 2 Στις βάσεις NoSQL **σχεδιάζουμε με βάση τα ερωτήματα:** ό,τι διαβάζεται μαζί, αποθηκεύεται μαζί.
- 3 Οι δηλώσεις xAPI είναι **έγγραφα JSON:** γι' αυτό τα δεδομένα μάθησης αποθηκεύονται συχνά σε βάσεις εγγράφων.

Διάλειμμα

Επιστρέφουμε σε 15'

15:00

Στο διάλειμμα, ξεκινήστε τη λήψη: mongodb.com/try/download/community (Windows, msi) και mongodb.com/try/download/shell (msi). Στο Μέρος 3 τα εγκαθιστούμε μαζί.